

Grundlagen aus der Statistik

Bevor wir über ML reden können brauchen wir ein paar elementare Grundlagen & Begriffe aus der Statistik.

1.1) Zufallsexperimente & Zufallsvariablen

Prozesse, die in der realen Welt ablaufen lassen sich mit Hilfe des folgenden Konzeptes beschreiben:

ZUFALLSEXPERIMENT



Würfeln

ELEMENTAREREIGNISSE

- mögl. Ergebnisse
- $\omega_1 = 1, \omega_2 = 2, \dots, \omega_6 = 6$

EREIGNISRAUM

$$\begin{aligned} \Omega &= \{\omega_i \mid i=1,2,\dots,6\} \\ \Omega &= \{1,2,3,4,5,6\} \end{aligned}$$

Mit welcher Wahrscheinlichkeit beobachtet man ein bestimmtes ω_i ??

SATZ

Satz von Laplace

Sind alle ω_i ($i=1, \dots, n$) gleich wahrscheinlich, dann gilt:


$$P(\omega_i) = \frac{1}{|\Omega|}$$

$i=1, \dots, n$

$|\Omega|=n$

Möglichkeit des
Ereignisraumes Ω

Bsp.: Glücksrad



Experiment: ω_i ($i=1,2,3$)

"Rad drehen"

$\omega_1 = \text{Sonne}$

$\omega_2 = \text{Haus}$

$\omega_3 = \text{Blume}$

$\Omega = \{\text{Sonne, Haus, Blume}\}$

$|\Omega|=3$

$P(\omega_i) = \frac{1}{3}$ für $i=1,2,3$

ABER

Wie beschreibt man komplexere Abläufe?

Würfelspiel: "Einsatz = 3 €, Gewinn: gewürfelte Augenzahl in €"

Beobachtung: Höhe des Gewinnes hängt vom Experiment "Würfeln" und $P(\omega_i)$ ab...

Def.: Zufallsvariable (ZV)

Eine ZV X ist eine Abbildung

$$X: \Omega \rightarrow \mathbb{R}$$


$$\omega_i \mapsto X(\omega_i) = x_i \in \mathbb{R}$$

Jedem Elementarereignis ω_i wird ein konkreter Wert $x_i \in \mathbb{R}$ zugeordnet.

Die $x_i \in \mathbb{R}$ heißen Realisierungen der ZV X .

Wir unterscheiden 2 Szenarien:

- einzelne $x_i \in \mathbb{R}$ \Rightarrow DISKRETE ZV X



- kontinuierliche x_i \Rightarrow STETIGE ZV X




Bsp. ① Würfelspiel (diskret)

$X \hat{=} \text{"Augenzahl} \times 2 \text{ in €"}$

$$\omega_1 = 1 \mapsto X(\omega_1) = 2 \cdot 1 = 2 \text{ €}$$

$$\omega_2 = 2 \mapsto X(\omega_2) = 2 \cdot 2 = 4 \text{ €}$$




Bsp. ② Wartezeit (stetig)

$X \hat{=} \text{"Zeit, bis der nächste Bus kommt"}$

$$\omega_1 = 0 \mapsto X(\omega_1) = 0 \text{ min}$$

⋮



FRAGE Wie bestimmt man die Wahrscheinlichkeiten der Realisierungen $x_i \in \mathbb{R}$?

→ Unterschiede zwischen diskreten und stetigen ZV...

1.2) W-Funktion & Verteilungsfunktion (DISKRETE ZV)

Def.: W-Funktion


Sei X eine diskrete ZV, $x_i \in \mathbb{R}$, $x_i \in \mathbb{R}$ ($i=1,2,\dots,n$) Realisierungen von X

dann heißt

$$f_X(x) = \begin{cases} P(X=x_i) = p_i & \text{für } x=x_i \ (i=1,2,\dots,n) \\ 0 & \text{sonst} \end{cases}$$

W-Funktion von X . Die W-Funktion ordnet jedem $x \in \mathbb{R}$ eine

Wahrscheinlichkeit zu



Es gilt:

$$\sum_{i=1}^n f_X(x_i) = \sum_{i=1}^n p_i = 1$$

und

$$0 \leq f_X(x_i) = p_i \leq 1$$

Axiome von Kolmogorow !!

Die Funktion

$$\bar{F}_X(x) = P(X \leq x) = \sum_{x_i \leq x} f(x_i)$$


heißt Verteilungsfunktion von X.

Bsp. 1) Fortsetzung


$X \stackrel{\text{def}}{=} \text{"Augengesamtwert in €"}$

$$x_i \in \{2, 4, 6, 8, 10, 12\}$$

$$P(X=x_i) = \frac{1}{6}$$



W-Funktion
von X



Verteilungsfunktion
von X

Bsp. 2) Wartezeit (Forts.)

$X = \text{"Zeit bis der nächste Bus kommt"}$

$$\omega_i \in [0; 30] \subset \mathbb{R}$$



Frage: Welche Wahrscheinlichkeit hat
 $X = 23 \text{ min}$ oder
 $x_i = 12 \text{ min } 20 \text{ s. } ??$

offensichtlich nicht so einfach, denn ∞ viele $x_i \dots$

1.3) W-Dichte & Verteilungsfunktion (STETIGE ZV)

für stetige ZV X gilt: $x_i \in I \subseteq \mathbb{R}$ 

Die Realisierungen kommen aus einem Kontinuum, es gibt also ∞ viele davon! 

\Rightarrow man kann einem einzelnen $x_i \in I \subseteq \mathbb{R}$ keine sinnvolle Wahrscheinlichkeit zuordnen!

Die Idee von der W-Funktion klappt hier nicht...

Denn:

wäre $P(X=x_i) = p_i \in [0;1]$ für $x_i \in I \subseteq \mathbb{R}$

dann müsste gelten

$$\sum_{i=1}^{\infty} p_i = 1$$



Wir brauchen eine andere Idee!

Def: W-Dichte

Sei X eine stetige ZV, $x \in \mathbb{R}$. Dann lässt sich X durch eine reelle Funktion mit den folgenden Eigenschaften beschreiben:

$$\begin{array}{l} \textcircled{1} \quad f_X(x) \geq 0 \\ \textcircled{2} \quad \int_{-\infty}^{\infty} f_X(x) dx = 1 \end{array}$$

$f_X(x)$ heißt W-Dichte von X und es gilt:


$$P(a \leq X \leq b) = \int_a^b f_X(x) dx \quad a, b \in \mathbb{R}$$

Für die Verteilungsfunktion von X folgt:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

und es gilt:


$$P(a \leq X \leq b) = F_X(b) - F_X(a)$$



Bemerkung: Die W-Dichte (W-Funktion) und die Verteilungsfunktion beschreiben die ZV X vollständig & gleichwertig

Bsp. 3) TK-Kost

Ein Kühlkoffer transportiert TK-Kost.



Die Temperatur darf nie über -18°C steigen,

die Aggregate haben aber eine Toleranz von 2°C . Es wird also auf -20°C gehöhlt, damit eventuelle Abweichungen noch ok. sind.


$X \stackrel{\text{?}}{=} \text{"Abweichungen vom Soll in } ^\circ\text{C"}$ mit W-Dichte $f_X(x) = \begin{cases} \frac{1}{12}(8-x^3) & x \in [0, 2] \\ 0 & \text{sonst} \end{cases}$

- Zeigt $f_X(x)$ tatsächlich eine zulässige W-Dichte?
- Wie lautet die Verteilungsfunktion $F_X(x)$?
- Wie wahrscheinlich sind Abweichungen von 0 bis 1°C ?

Lösung:

a) zu prüfen ist ① $f_x(x) \geq 0$ ($x \in \mathbb{R}$)

② $\int_{-\infty}^{\infty} f_x(x) dx = 1$



① $\frac{1}{12} \geq 0$ und $x^3 \in [0; 8]$ für $x \in [0; 2] \Rightarrow 8-x^3 \geq 0 \quad \checkmark$

② $\int_{-\infty}^{\infty} f_x(x) dx = \int_{-\infty}^0 0 dx + \int_0^2 \frac{1}{12}(8-x^3) dx + \int_2^{\infty} 0 dx = \frac{1}{12} \left[8x - \frac{1}{4}x^4 \right]_0^2 =$
 $= \frac{1}{12} [16 - 4] = \frac{12}{12} = 1 \quad \checkmark$

Aus ① + ② folgt: $f_x(x)$ ist eine zulässige W-Dichte!

$$\begin{aligned}
 b) F_X(x) &= \int_{-\infty}^x f_X(t) dt = \int_{-\infty}^0 0 dt + \int_0^x \frac{1}{12}(8-t^3) dt = \frac{1}{12} \left[8t - \frac{1}{4}t^4 \right]_0^x = \\
 &= \frac{1}{12} 8x - \frac{1}{48} x^4 = \frac{2}{3}x - \frac{1}{48}x^4 \quad \leftarrow \text{Verteilungsfunktion von } X
 \end{aligned}$$

$$\begin{aligned}
 c) P(0 \leq X \leq 1) &= \int_0^1 f_X(x) dx = \frac{1}{12} \int_0^1 (8-x^3) dx = \frac{1}{12} \left[8x - \frac{1}{4}x^4 \right]_0^1 = \\
 &= \frac{1}{12} \left(8 - \frac{1}{4} \right) = \frac{31}{48} = 0,6458 \stackrel{!}{=} 64,58\%
 \end{aligned}$$

Die Wahrscheinlichkeit beträgt 64,58%.

Es ist auch möglich die Verteilungsfunktion zu benutzen:

$$P(0 \leq X \leq 1) = F_X(1) - F_X(0) = \left(\frac{2}{3} - \frac{1}{48} \right) - 0 = 0,6458$$

⇒ Beide Lösungen sind absolut gleichwertig! ☺

1.4) Erwartungswert & Varianz

ZV lassen sich über ihre W-Dichte (W-Funktion) bzw. die Verteilungsfunktion vollständig beschreiben. Sie haben aber auch charakteristische Merkmale, die schon sehr viel über sie aussagen.



ERWARTUNGSWERT
(Lagemaf)

VARIANZ
(Streuungsmaß)

Def.: Erwartungswert

Sei X eine ZV mit Realisierungen $x_i \in \mathbb{R}$

Dann ist der Erwartungswert $E(X)$ definiert als:

DISKRETE ZV



$$E(X) = \sum_{i=1}^n x_i \cdot f_X(x_i)$$

← Mittelwert der Realisierungen
gewichtet mit ihren Wahrscheinlichkeiten

STETIGE ZV



$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x) dx$$

← $E(X)$ hat die Einheit der ZV
z.B. €, $\frac{m}{s}$, \$,...

Rechenregeln:

$X, Y \in V$

$a, b, c \in \mathbb{R}$

$$E(a) = a$$

$$E(X+Y) = E(X) + E(Y)$$

$$E(a+X) = a + E(X)$$

$$E(aX+bY+c) = aE(X) + bE(Y) + c$$

$$E(a \cdot X) = a \cdot E(X)$$

Bsp. 3) Fortsetzung

$$f_X(x) = \frac{1}{12}(8-x^3)$$

$$x \in [0; 2]$$

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty} x \cdot f_X(x) dx = \int_0^2 x \cdot \frac{1}{12}(8-x^3) dx = \frac{1}{12} \int_0^2 8x - x^4 dx = \\ &= \frac{1}{12} \left[8 \cdot \frac{1}{2}x^2 - \frac{1}{5}x^5 \right] \Big|_0^2 = \frac{4}{5} = 0,8 \end{aligned}$$

\Rightarrow Es ist erwartungsgemäß mit einer Abweichung von $0,8^\circ\text{C}$ zu rechnen.

 Der Erwartungswert ist also derjenige Wert, den man "am wahrscheinlichsten" beobachtet.

In der deskriptiven Statistik: $\xrightarrow{\text{Zugemis}} \xrightarrow{\text{Median}} \text{Rückschluss}$ \leftarrow interessantlich die Streuung \Rightarrow Standardabweichung

Def.: Varianz

Die Varianz einer ZV X entspricht der erwarteten quadratischen Abweichung der möglichen Werte vom Erwartungswert.

DISKRETE ZV



$$V(X) = \sum_{i=1}^k (x_i - E(X))^2 \cdot f_X(x)$$

← Einheiten los!

STETIGE ZV



$$V(X) = \int_{-\infty}^{\infty} (x - E(X))^2 \cdot f_X(x) dx$$

$\sigma_x = \sqrt{V(X)}$ heißt Standardabweichung von X (Einheit von X)

Für zwei unabhängige ZV X, Y ($P(X \leq x, Y \leq y) = P(X \leq x) \cdot P(Y \leq y)$) gelten die folgenden Rechenregeln:

$a \in \mathbb{R}$

X, Y unabh
ängig

$$V(a) = 0$$

$$V(X + Y) = V(X) + V(Y)$$

$$V(a + X) = V(X)$$

$$V(a \cdot X) = a^2 V(X)$$

Bsp. 3) Fortsetzung

$$f_x(x) = \frac{1}{12}(8-x^3)$$

$$E(X) = \frac{4}{5}$$


$$V(x) = \int_0^2 \left(x - \frac{4}{5}\right)^2 \cdot \frac{1}{12}(8-x^3) dx = \dots = 0,2489$$

$$\Rightarrow \sigma_x = \sqrt{V(x)} = \sqrt{0,2489} = 0,4989 \text{ [°C]}$$

Die Beschreibung von Abläufen, die von Zufall geprägt sind wird also mit Hilfe von ZV gemacht.

Allerdings: Die ZV X selbst ist ein abstraktes Konstrukt

In der Realität gilt:




~~WIR~~ wir "sehen" in der echten Welt immer nur die REALISIERUNGEN $x_i \in ℝ$



2. Induktive Statistik - "Lernen aus Daten"


Bisher: theoretischer Unterbau & Konzepte

Jetzt: wir schen / beobachten / messen \Rightarrow Daten! und was weiter? ?



KONZEPT: hinter jeder Beobachtung steht eine ZV X mit einer beschreibenden Verteilungsfunktion.

Die beobachteten Daten entsprechen (den) Realisierungen dieser ZV X .



Ziehe aus den Beobachtungen Rückschlüsse auf die zugrundeliegende ZV: \rightarrow Verteilungsfkt., Parameter?
 $\rightarrow E(X) = ?$
 $\rightarrow V(X) = ?$

bei mehrdimensionalen Größen


$X = (X_1, X_2)$ oder 2 ZV X, Y geht es darum, Zusammenhangsstrukturen (mehrdim. Verteilungsfunktion) aufzudecken und zu modellieren.

2.1 Stichproben & Schätzer

Allgemein: Elemente einer (sehr großen) Grundgesamtheit haben eine bestimmte Eigenschaft

Bsp.: Personen über 18 in Deutschland
Führerschein? \rightarrow ja (1)
 \rightarrow nein (0)

- repräsentativen Ausschnitt wählen
- Daten erheben
- Daten auswerten



Rückschlüsse ziehen über
z.B. $X \geq$ "Führerschein?"

Def.: Stichprobe

Eine n -dim RV $X = (X_1, \dots, X_n)$ heißt Stichprobe, wenn die RV X_i ($i=1, \dots, n$) unabhängig und identisch verteilt genüg der Grundgesamtheit sind.

Die Stichprobenziehung liefert eine Realisierung $x = (x_1, \dots, x_n)$ von X , wobei x_i die Realisierungen der X_i ($i=1, \dots, n$) sind.
Die Dimension n der Stichprobe heißt Stichprobengröße.

$$\begin{aligned} E(X) &= \mu \quad \text{Erwartungswert} \\ V(X) &= \sigma^2 \quad \text{Variance} \end{aligned} \quad \left. \begin{array}{l} \text{im der} \\ \text{GRUNDGESAMTHEIT} \end{array} \right\} \quad \Rightarrow \quad \text{Unbekannt}$$

 müssen aus den Daten (Realisierungen $x = (x_1, \dots, x_n)$) geschätzt werden.

Bsp.: Führerschein

Grundgesamtheit:
alle ü-18

Stichprobe der Länge
 $n = 1000$
repräsentativ: X_i unabh.
gleiche Frage: X_i id. verteilt

Zelung
 $x = (1, 0, \dots, 1, 1, 0)$
Realisierung \ Daten



Wie schätzt man den Erwartungswert
 $E(X)$, also die Wahrscheinlichkeit
für eine "ja"-Antwort bei einer
beliebigen Person?

... was würden Sie mit der Realisierung $x = (1, 0, \dots, 1, 1, 0)$ anfangen??

Def.: Schätzfunktion & Schätzung

Sei Θ ein beliebiger unbekannter Parameter der Verteilung

$F_\Theta(x)$ und $X = (X_1, \dots, X_n)$ eine Stichprobe mit Realisierung $x = (x_1, \dots, x_n) \in \mathbb{R}^n$, dann heißt

$$T_\Theta(X) = T_\Theta(X_1, \dots, X_n)$$

Schätzfunktion von Θ (ZV)

$$\hat{\Theta} = T_\Theta(x_1, \dots, x_n) = t_\Theta(x_1, \dots, x_n)$$

Schätzung von Θ ($\hat{\Theta} \in \mathbb{R}$)

Wichtige Eigenschaft: ERWARTUNGSTREUE

$$E(T_\Theta(X)) = \Theta$$

Bei α viele Wiederholungen der Schätzung konvergiert der Mittelwert der $\hat{\Theta}$ gegen das "wahre" Θ !!

... Schätzer sind oft so konstruiert, daß sie erwartungstreu sind. Falls nicht gibt es einen BIAS

$$\text{bias}(T_Q(X)) = E(T_Q(X)) - Q \quad \leftarrow \text{Bsp für die Verzerrung}$$

Bsp.: Schätzung für Erwartungswert & Varianz

① Erwartungswert

$$X = (X_1, \dots, X_n)$$

$$x = (x_1, \dots, x_n)$$

$$E(X_i) = \mu \quad (i=1, \dots, n)$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

: BIAS?

$$: E(T_f(x)) =$$

$$T_g(X) = \frac{1}{n} \sum_{i=1}^n X_i$$

~

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$$

Schätzung von μ

Schätzer für $E(x)$

② Varianz

$$T_{\hat{\theta}^2}(x) = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

► w.g. Erwartungstreue nötig !!!

Bemerkung: Selbst wenn die Schätzfunktion erwartungstreu ist ($\Rightarrow \text{bias} = 0$), gibt es immer noch einen Fehler beim Schätzen. Der hängt von der Varianz der Schätzfunktion ab !!

► Def.: MSE - Mean Squared Error

falls $T_\theta(x)$
erwartungstreu

$$\text{MSE}(T_\theta(x)) = E((T_\theta(x) - \theta)^2) = \text{Var}(T_\theta(x)) + \text{bias}(T_\theta(x))^2$$

Bemerkung:

$$\sigma_{T_\theta}(x) = \sqrt{\text{Var}(T_\theta(x))}$$

heißt Standardfehler der Schätzung

Bsp. 4) Service-Center

| i | 1 | 2 | 3 | 4 | 5 |
|--------|----|----|----|----|----|
| # | 20 | 27 | 35 | 53 | 42 |
| Anrufe | | | | | |

$$X = (x_1, \dots, x_5) \quad n=5$$
$$x = (20, 27, 35, 53, 42)$$

$$E(x) = \hat{f} = ? \quad \hat{f} = \frac{1}{5} (20 + 27 + \dots + 42) = 35,4 \quad (\text{Anrufe})$$

$$\text{Var}(x) = \hat{\sigma}^2 = ? \quad \hat{\sigma}^2 = \frac{1}{4} ((20 - 35,4)^2 + \dots + (42 - 35,4)^2) = 165,3$$

$$\hat{\sigma} = 12,86 \quad (\text{Standardfehler})$$



Welche Möglichkeiten hat man zusätzlich zum Standardfehler der Schätzung um die Unsicherheit der Schätzung zu bewerten?

→ Konfidenzintervalle

→ Hypothesentests



MEHR IN DER STATISTIK-VORESUNG