

## 2.1.3) Linearisierbare Modelle


Bisher sind wir davon ausgegangen, daß die Modellfunktion

$f(x_1, \dots, x_m)$  mit  $Y = f(x_1, \dots, x_m) + \varepsilon$  linear ist, also

$$f(x_1, \dots, x_m) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_m x_m$$

Das ist aber leider nur selten der Fall ...




- Bsp.:
- Jäger - Beute Beziehung
  - Bakterienwachstum (Epidemie)
  - periodische Abläufe



→ Schätzgerade  $\hat{g}$  läßt sich (mathematisch gesehen) problemlos für die Daten berechnen

→  $\hat{p}$  passt aber deutlich besser zur Zusammenhangsstruktur

Eine Analyse der Residuen könnte wie folgt ausssehen:



☞ Die Analyse der Residuen zeigt für  $\hat{g}$  eine deutliche Systematik  
 $\hat{=}$  Systematik des Fehlers  $\varepsilon \hat{=}$  bias des linearen Modells



Verwende für das Modell keine lineare Funktion  
sondern ein Polynom, Exponentialfunktion ...

Polynom:  
in  $X_1, \dots, X_m$

$$f(X_1, \dots, X_m) = b_0 + b_1 X_1 + b_2 X_1^2 + \dots + b_e X_m^e$$

← ziemlich komplex!

zich vermischte Terme  $b_j X_i X_k$  möglich!

## 2 FRAGEN

- ① Wie findet man die unbekannten Parameter  $b_j$ ?
- ② Welche Modellstruktur ist geeignet, d.h. welche  $X_j$  und bis zu welchem Grad bzw. in welchen Kombis  $X_j X_k$ ?

Wir starten einfach:

I

Polynom  
(univariat)  
im X

Modell:

$$Y = b_0 + b_1 X + b_2 X^2 + \dots + b_k X^k + \varepsilon$$

$k$ : Grad des  
Polynoms

für Datenpunkte  $i=1\dots,n$   $(x_i, y_i)$  gilt dann

Lösung ??  
 $\hat{b} = \begin{pmatrix} b_0 \\ \vdots \\ b_n \end{pmatrix} = ??$

$$\hat{y}_i = b_0 + b_1 x_i + b_2 x_i^2 + \dots + b_k x_i^k + \varepsilon_i$$

empirische  
Beziehung

IDEE Die Struktur des Modells

sieht aus wie

$$Y = b_0 + b_1 X + b_2 X^2 + \dots + b_k X^k + \varepsilon$$

$$Y = b_0 + b_1 X_1 + b_2 X_2 + \dots + b_k X_k + \varepsilon$$

multiv. lineares  
Modell  
Lösung bekannt !!

→ Variablentransfo:

$$\begin{aligned} X &:= X_1 \\ X^2 &:= X_2 \\ &\vdots \\ X^k &:= X_k \end{aligned}$$

\* hat (in den neuen Variablen)  
offensichtlich die gleiche Lösung

$$\hat{b} = (X^t \cdot X)^{-1} \cdot X^t \cdot \vec{y}$$

≈ Datenmatrix  $X$  muss entsprechend befüllt werden ...

Es gilt:

$$X = \begin{bmatrix} 1 & x_1 & x_1^2 & \dots & x_1^k \\ 1 & x_2 & x_2^2 & \dots & x_2^k \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^k \\ \uparrow & \uparrow & \uparrow & \ddots & \uparrow \\ X & X^2 & \cdots & X^k \end{bmatrix}$$

$$\vec{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

$$\vec{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_m \end{pmatrix}$$

$$\hat{b} = (X \cdot X^t)^{-1} \cdot X^t \cdot \vec{y}$$

Eine entsprechende Schätzung für  $y_i$  (Prognose) ergibt sich als

$$\hat{y}_i = \hat{b}_0 + \hat{b}_1 x_i + \hat{b}_2 x_i^2 + \dots + \hat{b}_k x_i^k$$

$$\hat{\varepsilon}_i = y_i - \hat{y}_i$$

← Residuum

mit Standardfehler aus

$$\hat{\sigma}^2 = \frac{1}{m-(k+1)} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

← abhängig vom Grad  $k$  des Polynoms.

Bemerkung: zu hohe Polynomgrade sind i.A. nicht sinnvoll (overfitting).

Fäustregel:  $k \leq 4$

## Bsp.1) Verkaufszahlen

3 Produkte A,B,C


4 Kunden ( $i=1, \dots, 4$ )

$x_1, x_2, Y \in \mathbb{Z}^V$

$\hat{\cdot}$  "gekaufte Stückzahl A,B,C"

i	Y	$x_1$	$x_2$
1	2	2	2
2	4	6	2
3	6	6	4
4	4	4	4

A    B    C



aus der Anzahl der gekauften B und C soll eine Stückzahl für A ermittelt werden!

Vermutung

$$Y = b_0 + b_1 X_1 + b_2 X_1^2 + \epsilon$$

$$\vec{y} = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 4 \end{pmatrix}$$

$$X = \begin{bmatrix} 1 & 2 & 4 \\ 1 & 6 & 36 \\ 1 & 6 & 36 \\ 1 & 4 & 16 \end{bmatrix}$$

$$x_1 \quad x_1^2$$

$$\Rightarrow \hat{\vec{b}} = (\vec{X}^t \cdot \vec{X})^{-1} \cdot \vec{X}^t \cdot \vec{y} \quad \stackrel{\text{Computer}}{\Rightarrow} \quad \hat{\vec{b}} = \begin{pmatrix} -1 \\ 1,75 \\ -0,125 \end{pmatrix}$$

$$\Rightarrow \hat{y}_i = -1 + 1,75 x_{i1} - 0,125 x_{i1}^2 \quad \leftarrow \text{Prognose}$$

	$y_i$	$\hat{y}_i$	$\hat{\epsilon}_i$
1	2	2	0
2	4	5	-1
3	6	5	1
4	4	4	0

$$\Rightarrow \hat{\sigma}^2 = \frac{1}{n-(k+1)} \sum_{i=1}^4 \hat{\epsilon}_i^2 = \frac{1}{4-3} \cdot 2 = 2$$

$$\Rightarrow \hat{\sigma} = \sqrt{2} = 1,41 \quad \leftarrow \text{Standardfehler}$$

Um zu testen, ob  $X_2$  im Modell Sinn macht

$$\begin{aligned} H_0: b_2 &= 0 \\ H_1: b_2 &\neq 0 \end{aligned}$$

mit  $\alpha$ -Fehler  
bekannt!

mit Teststatistik:

$$\hat{T}_{b_2} = \frac{\hat{b}_2 - 0}{\hat{\sigma}_{\hat{b}_2}}$$

geschätzte Varianz  
von  $b_2$

und krit. Bereich:

$$K = (-\infty; -t(m-k)_{1-\frac{\alpha}{2}}) \cup (t(m-k)_{1-\frac{\alpha}{2}}; +\infty)$$

$(1-\frac{\alpha}{2})$  Quantil der  
 $t$ -Verteilung mit  $(m-k)$  FG  
(Tabelle oder Computer)

Bemerkung:

Die geschätzte Varianz von  $b_2$  bekommt man aus der Kovarianzmatrix

$$\hat{\Sigma} = \hat{\sigma}^2 (X^t \cdot X)^{-1}$$

die Diagonalelemente von  $\hat{\Sigma}$  entsprechen den geschätzten Varianzen von  $b_0, b_1, \dots, b_k$

Bsp. 1) Fortsetzung

$$\hat{\Sigma} = \begin{bmatrix} 37 & * & * \\ * & 11,69 & * \\ * & * & 0,17 \end{bmatrix}$$

⇒ Konfidenzintervall für  $b_1$ :

$$\hat{I}_{b_1} = \left[ \hat{b}_1 \pm t(n-k)_{1-\frac{\alpha}{2}} \hat{\sigma}_{\hat{b}_1} \right] =$$

$$= [1,75 \pm 12,706 \cdot \sqrt{11,69}] = [-41,69; 45,19]$$

ganz schön breit !!

⇒ Schätzung ungenau



Hypothesentest:

$$\begin{cases} H_0: b_2 = 0 \\ H_1: b_2 \neq 0 \end{cases}$$

$$\hat{T} = \frac{-0,125 - 0}{\sqrt{0,17}} = -0,3$$


↑  
Tabelle

$$\left. \begin{array}{l} \Rightarrow \hat{T} = -0,3 \notin K \Rightarrow H_0 \text{ annehmen} \\ \Rightarrow t_1 \text{ nicht berücksichtigen !! } X_1^L \text{ vermutlich nicht relevant} \end{array} \right\}$$

$$K = (-\infty; -12,7) \cup (12,7; \infty)$$

## Bsp.: Eisverkauf

je schöner das Wetter  
desto mehr wird verkauft




Polymerialer Zusammenhang zwischen X und Y

7/1

$$f(x) = b_0 + b_1 x + b_2 x^2 + \dots + b_k x^k$$

... wir starten einfach (lin. Einfach regression) und schauen mal ...

①



→ Polynom Grad 1

geschätzte Parameter:

$$\hat{b}_0 = -340$$

$$\hat{b}_1 = 40,37 \text{ (pos. lin. Zshg.)}$$

Bestimmtheitsmaß:

$$R^2 = 0,894$$

Das Modell passt von seiner Struktur her gut zu den Daten. Einzelne Datenpunkte ändern das Ergebnis für  $\hat{b}_0$ ,  $\hat{b}_1$  kaum!

#### OLS Regression Results


Dep. Variable:	y	R-squared:	0.894
Model:	OLS	Adj. R-squared:	0.885
Method:	Least Squares	F-statistic:	101.4
Date:	Wed, 25 Oct 2023	Prob (F-statistic):	3.33e-07
Time:	10:30:36	Log-Likelihood:	-80.096
No. Observations:	14	AIC:	164.2
Df Residuals:	12	BIC:	165.5
Df Model:	1		
Covariance Type:	nonrobust		
coef	std err	t	P> t
const	-340.9114	84.037	-4.057
x1	40.3691	4.010	10.067
Omnibus:	5.634	Durbin-Watson:	1.301
Prob(Omnibus):	0.060	Jarque-Bera (JB):	2.540
Skew:	0.875	Prob(JB):	0.281
Kurtosis:	4.138	Cond. No.	82.8

Polynom vom Grad 2 →

$$X = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix}$$

↑ const    ↑ X    ↑ X<sup>2</sup>

$$f(x) = b_0 + b_1 X + b_2 X^2$$



65

### OLS Regression Results

Dep. Variable:	y	R-squared:	0.942			
Model:	OLS	Adj. R-squared:	0.931			
Method:	Least Squares	F-statistic:	89.15			
Date:	Wed, 25 Oct 2023	Prob (F-statistic):	1.60e-07			
Time:	10:34:47	Log-Likelihood:	-75.897			
No. Observations:	14	AIC:	157.8			
Df Residuals:	11	BIC:	159.7			
Df Model:	2					
Covariance Type:	nonrobust	click to scroll output; double click to hide				
	coef	std err	t	P> t	[0.025	0.975]
const	349.1834	238.543	1.464	0.171	-175.847	874.214
x1	-28.0818	22.976	-1.222	0.247	-78.651	22.487
x2	1.5881	0.528	3.007	0.012	0.426	2.751
Omnibus:	1.343	Durbin-Watson:			1.561	
Prob(Omnibus):	0.511	Jarque-Bera (JB):			0.806	
Skew:	-0.130	Prob(JB):			0.668	
Kurtosis:	1.854	Cond. No.			7.22e+03	

←  $R^2 = 0,942$  (gerhiegen)

← ABER: p-Werte gerhiegen ...


↳ kleine Änderungen im Datensatz zeigen schon einen Einfluss ...

Polynom vom Grad 3 →

$$X = \begin{bmatrix} 1 & x_1 & x_1^2 & x_1^3 \\ 1 & x_2 & x_2^2 & x_2^3 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_m & x_m^2 & x_m^3 \end{bmatrix}$$

↑ Const    ↑  $x$     ↑  $x^2$     ↑  $x^3$

$$f(x) = b_0 + b_1 x + b_2 x^2 + b_3 x^3$$



### OLS Regression Results


```
=====
Dep. Variable: y R-squared: 0.978
Model: OLS Adj. R-squared: 0.972
Method: Least Squares F-statistic: 150.0
Date: Wed, 25 Oct 2023 Prob (F-statistic): 1.30e-08
Time: 10:36:06 Log-Likelihood: -69.014
No. Observations: 14 AIC: 146.0
Df Residuals: 10 BIC: 148.6
Df Model: 3
Covariance Type: nonrobust
=====
```

$\leftarrow R^2 = 0,978$

	coef	std err	t	P> t	[0.025	0.975]
const	-1871.2232	563.948	-3.318	0.008	-3127.777	-614.670
x1	311.6791	84.354	3.695	0.004	123.726	499.632
x2	-14.9056	4.046	-3.684	0.004	-23.921	-5.890
x3	0.2546	0.062	4.091	0.002	0.116	0.393

$\leftarrow p\text{-Werte klein}$

```
Omnibus: 2.607 Durbin-Watson: 3.015
Prob(Omnibus): 0.272 Jarque-Bera (JB): 1.795
Skew: -0.710 Prob(JB): 0.408
Kurtosis: 1.971 Cond. No. 6.96e+05
=====
```



→ Polynom Grad 12

⚠️ 14 Datenpunkte! 13 Parameter!

⇒ die Schätzung ist bereits numerisch instabil!

↑ deutliches overfitting !!

läßt man 1 Datenpunkt weg, dann ändert sich die Form des Polynoms komplett!

⇒ p-Werte zeigen, daß das Modell deutlich zu komplex ist!

(obwohl  $R^2$  top ist auf der Trainingsmenge!) < Testmenge !!

OLS Regression Results									
Dep. Variable:	y	R-squared:	0.986						
Model:	OLS	Adj. R-squared:	0.974						
Method:	Least Squares					81.15			
Date:	Wed, 25 Oct 2023					4.10e-06			
Time:	10:37:00					-66.021			
No. Observations:	14	Log-Likelihood:		AIC:	146.0				
Df Residuals:	7	BIC:			150.5				
Df Model:	6	Covariance Type:	nonrobust						
	coef	std err	t	P> t	[0.025	0.975]			
const	2.731e-08	3.91e-08	0.699	0.507	-6.5e-08	1.2e-07			
x1	-1.666e-06	2.38e-06	-0.699	0.507	-7.3e-06	3.97e-06			
x2	2.159e-06	3.08e-06	0.700	0.507	-5.14e-06	9.45e-06			
x3	1.646e-05	2.35e-05	0.700	0.506	-3.91e-05	7.21e-05			
x4	0.0001	0.000	0.701	0.506	-0.000	0.000			
x5	0.0005	0.001	0.702	0.505	-0.001	0.002			
x6	0.0014	0.002	0.706	0.503	-0.003	0.006			
x7	-0.0004	0.001	-0.608	0.562	-0.002	0.001			
x8	3.953e-05	7.04e-05	0.561	0.592	-0.000	0.000			
x9	-2.327e-06	4.3e-06	-0.541	0.605	-1.25e-05	7.84e-06			
x10	7.767e-08	1.45e-07	0.535	0.609	-2.65e-07	4.21e-07			
x11	-1.383e-09	2.57e-09	-0.538	0.607	-7.46e-09	4.69e-09			
x12	1.02e-11	1.87e-11	0.546	0.602	-3.4e-11	5.44e-11			
Omnibus:		0.921	Durbin-Watson:		3.362				
Prob(Omnibus):		0.631	Jarque-Bera (JB):		0.806				
Skew:		-0.366	Prob(JB):		0.668				
Kurtosis:		2.081	Cond. No.		8.42e+22				

→ Vermutung: Allgemein wäre es gut auch  $X_1, \dots, X_p$  berücksichtigen zu können – mit beliebigem polynomialen Grad ...

II.

Polynom  
multivariat  
 $X_1, \dots, X_m$

Modell

$$Y = b_0 + b_1 X_1 + b_2 X_1^2 + \dots + b_j X_i X_j + \dots + \dots + \varepsilon$$

⇒ schon bei 2 erklärenden Größen wird das i.Ä. sehr komplex ..



$$Y = b_0 + b_1 X_1 + b_2 X_1^2 + b_3 X_1 X_2 + b_4 X_2 + b_5 X_2^2 + \varepsilon$$

Die Lösungsidee (VARIABLENTRAFO) bleibt aber die gleiche

Setze

$$\begin{aligned} X_1 &= \tilde{X}_1 \\ X_1^2 &= \tilde{X}_2 \\ X_1 X_2 &= \tilde{X}_3 \\ X_2 &= \tilde{X}_4 \\ X_2^2 &= \tilde{X}_5 \end{aligned}$$



in

$$Y = b_0 + b_1 \tilde{X}_1 + b_2 \tilde{X}_2 + \dots + b_5 \tilde{X}_5 + \varepsilon$$

← Vorsicht beim Befüllen der Datenmatrix!

Reihenfolge ist entscheidend!

$$X = \begin{bmatrix} 1 & \tilde{X}_1 & \tilde{X}_2 & \dots & \tilde{X}_5 \\ 1 & \tilde{X}_1 & \tilde{X}_2 & \dots & \vdots \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \tilde{X}_1 & \tilde{X}_2 & \dots & \tilde{X}_5 \\ \tilde{X}_1 & \tilde{X}_2 & \dots & \tilde{X}_m \end{bmatrix}$$

Bsp. 1) Forts.

i	Y	X <sub>1</sub>	X <sub>2</sub>
1	2	2	2
2	4	6	2
3	6	6	4
4	4	4	4
A	B	C	

z.B.

$$\Rightarrow Y = b_0 + b_1 X_1^2 + b_2 X_2^2 + \varepsilon$$

$$X = \begin{bmatrix} 1 & 4 & 4 \\ 1 & 36 & 4 \\ 1 & 36 & 16 \\ 1 & 16 & 16 \\ 1 & X_1^2 & X_2^2 \end{bmatrix} \quad \vec{Y} = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 4 \end{pmatrix}$$

$$\Rightarrow \hat{\vec{b}} = (X^t \cdot X)^{-1} \cdot X^t \cdot \vec{Y} = \begin{pmatrix} 1,019 \\ 0,073 \\ 0,130 \end{pmatrix}$$

$$\hat{y}_i = 1,019 + 0,073 X_i^2 + 0,130 X_i^2$$

$$\hat{\varepsilon}_i = y_i - \hat{y}_i \quad (i=1,2,3,4)$$

propter  
als vorher

i	y <sub>i</sub>	$\hat{y}_i$	$\hat{\varepsilon}_i$
1	2	1,83	0,17
2	4	4,17	-0,17
3	6	5,73	0,22
4	4	4,27	-0,27

$$\Rightarrow \hat{\sigma}^2 = \frac{1}{n-(k+n)} \sum_i \hat{\varepsilon}_i^2 = \frac{1}{4-3} \sum_i \hat{\varepsilon}_i^2 = 0,20 \Rightarrow \hat{\sigma} = 0,45$$

Bemerkung: mit

$$\boxed{H_0: b_2 = 0}$$

$$H_1: b_2 \neq 0$$

← Test ob  $X_2^2$  im  
Modell Sinn macht ...

Blauerberg: die Lösungsweise lässt sich auf beliebige Modelle erweitern, die eine lineare "Grundstruktur" haben...

III.

Fourier-Synthese

Modell

Bsp.:

$$Y = b_0 + b_1 \cos(X) + b_2 \cos(2X) + b_3 \sin(X) + b_4 \sin(2X) + \varepsilon$$

... und beliebige weitere Terme ...  $\leftarrow$  (linear)

TRAFO

$$\begin{aligned} \cos(X) &= \tilde{X}_1 \\ \cos(2X) &= \tilde{X}_2 \\ \sin(X) &= \tilde{X}_3 \\ \sin(2X) &= \tilde{X}_4 \end{aligned}$$

in  $\Rightarrow$

$$Y = b_0 + b_1 \tilde{X}_1 + b_2 \tilde{X}_2 + b_3 \tilde{X}_3 + b_4 \tilde{X}_4 + \varepsilon$$

dann:


$$X = \begin{bmatrix} 1 & \cos(x_1) & \cos(2x_1) & \dots & \sin(2x_1) \\ 1 & \cos(x_2) & \cos(2x_2) & & \sin(2x_2) \\ \vdots & \vdots & \vdots & & \vdots \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & \cos(x_n) & \cos(2x_n) & & \sin(2x_n) \end{bmatrix}$$

$$\begin{array}{c} \uparrow \\ \cos(X) \end{array} \quad \begin{array}{c} \uparrow \\ \cos(2X) \end{array} \quad \cdots \quad \begin{array}{c} \uparrow \\ \sin(2X) \end{array}$$

$\Rightarrow$  ist besonders dann geeignet, wenn  $Y$  periodisch von  $X$  abhängt!

$\rightarrow$  Signalverarbeitung, Sound, etc.

Mit den bisherigen Überlegungen läßt sich schon viel machen. Was aber, wenn



← ganz anderer funktionaler Zusammenhang z.B. exponentiell...

IV

Exponentielle  
Regression

MODELL

$$Y = b_0 \cdot e^{b_n X} + \varepsilon$$


exponentielles  
Modell

ZV  $X, Y$  mit Realisierungen  $(x_i, y_i)$  ( $i=1, \dots, n$ )

⇒ empirische  
Beziehung

$$y_i = b_0 \cdot e^{b_n x_i} + \varepsilon_i$$

→ jetzt ist eine gute Idee gefragt ☺



**IDEE**

betrachte die empirische Beziehung:

$$y_i = b_0 \cdot e^{b_1 x_i}$$

← e-Funktion "stört"



wende die Umkehrfunktion  $\ln(\dots)$   
auf beiden Seiten der Gleichung an

$$\Rightarrow y_i = b_0 \cdot e^{b_1 x_i} \quad \left. \begin{array}{l} \\ \ln(\dots) \end{array} \right.$$

$$\ln(e^x) = x = e^{\ln(x)}$$

\*  $\ln(y_i) = \ln(b_0) + b_1 x_i$

Setze:

$$\begin{aligned} \ln(y_i) &= \tilde{y}_i \\ \ln(b_0) &= \tilde{b}_0 \end{aligned}$$



$$\tilde{y}_i = \tilde{b}_0 + b_1 x_i$$

← Lineare Einfachregression  
mit behaltneter Lösung 😊

TRAFO

... um auf das ursprüngliche Modell zu kommen müßt man am Ende zurück transf.!

Bsp. 1) Forts.

i	Y	X
1	2	2
2	4	6
3	6	6
4	4	4
A		B

← Vermutung:  $Y = b_0 \cdot e^{b_1 X} + \varepsilon$

$x_i$	$y_i$	$\ln(y_i) = \tilde{y}_i$
2	2	0,69
6	4	1,39
6	6	1,79
4	4	1,39

$$\bar{x} = 4,5 \quad s_x^2 = 2,75$$

$$\bar{\tilde{y}} = 1,315$$

$$\text{Cov}(x, \tilde{y}) = 0,5875$$

Lösung: 
$$\begin{aligned} \hat{b}_0 &= \bar{\tilde{y}} - \hat{b}_1 \bar{x} \\ \hat{b}_1 &= \frac{\text{Cov}(x, \tilde{y})}{s_x^2} \end{aligned}$$
 }  $\Rightarrow \begin{aligned} \hat{b}_1 &= \frac{0,5875}{2,75} = 0,21 \\ \hat{b}_0 &= 1,315 - 0,21 \cdot 4,5 = 0,37 \end{aligned}$

!  $\hat{b}_0$  muss rücktransf. werden:  $\hat{b}_0 = e^{\hat{b}_0} = 1,45 \Rightarrow \hat{y}_i = 1,45 \cdot e^{0,21 x_i}$

Prognose

Auswertung:

$y_i$	$\hat{y}_i$	$\hat{\varepsilon}_i$
2	2,20	-0,2
4	5,11	-1,11
6	5,11	0,89
4	3,36	0,64

$$\Rightarrow \hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^4 \hat{\varepsilon}_i^2 = 1,24$$

$$\Rightarrow \hat{\rho} = 1,11$$

(Polynommodell  $\hat{\sigma}^2 = 1,41 \Rightarrow$  leicht besser)

Bemerkung:

Das Modell lässt sich auch multivariat formulieren.

Dann

$$Y = b_0 \cdot e^{b_1 x_1 + b_2 x_2 + \dots + b_m x_m} + \varepsilon$$

logarithmieren  $\Rightarrow$

$$\ln(Y) = \ln(b_0) + b_1 x_1 + \dots + b_m x_m + \varepsilon$$

$\rightarrow$  Lösung wie beim multivariaten linearen Modell!

# ZUSAMMENFASSUNG:

115

Modell	$f(x)$	TRAFO	LÖSUNG	METRIK
lin. Einfach-regression	$b_0 + b_1 X$	keine	$\hat{b}_0 = \bar{y} - \hat{b}_1 \bar{x}$ $\hat{b}_1 = \frac{\text{cov}(x, y)}{s_x^2}$	$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\epsilon}_i^2$ $R^2 = \frac{SSE}{SQT}$
multiple Re-gression	$b_0 + b_1 X_1 + \dots + b_k X_k$	keine	$\hat{b} = (\hat{X}^t \cdot \hat{X})^{-1} \cdot \hat{X}^t \cdot \hat{y}$	$\hat{\sigma}^2 = \frac{1}{n-(k+1)} \sum_{i=1}^n \hat{\epsilon}_i^2$ korrigierter $R^2$
Polynom im $X$	$b_0 + b_1 X + b_2 X^2 + \dots + b_k X^k$	$X = \tilde{X}_1$ $X^2 = \tilde{X}_2$ $\vdots$ $X^k = \tilde{X}_n$	$\hat{b} = (\tilde{X}^t \tilde{X})^{-1} \cdot \tilde{X}^t \cdot \tilde{y}$	— " —
Polynom in $X_1, \dots$ (multipl.) (max. deg $\approx 4$ sinnvoll)	Bsp. $b_0 + b_1 X_1 + b_2 X_2 + b_3 X_1 X_2 +$ $+ b_4 X_1^2 + b_5 X_2^2$	$X_1 = \tilde{X}_1$ $X_2 = \tilde{X}_2$ $X_1 X_2 = \tilde{X}_3$ $\vdots$	— " —	— " —
Exponential-modell	$b_0 \cdot e^{b_1 X}$	$\ln(Y) = \tilde{Y}$ $\ln(b_0) = \tilde{b}_0$	$\hat{b}_0 = \bar{Y} - \hat{b}_1 \bar{X}$ $\hat{b}_1 = \frac{\text{cov}(x, \tilde{Y})}{s_x^2}$	$\hat{\sigma}^2 = \frac{1}{n-2} \sum_i \hat{\epsilon}_i^2$ $R^2 = \frac{SSE}{SQT}$