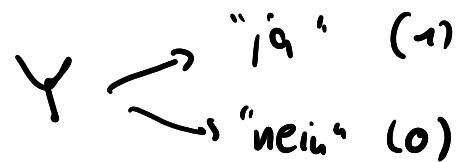


2.2.2) Diskriminanzanalyse

Schon gesehen: die Logistische Regression eignet sich besonders bei Zielgrößen, die binär sind



Im Fall von Y mit mehreren Ausprägungen sind andere Methoden besser geeignet \rightarrow z.B. Diskriminanzanalyse (klass. Verfahren)

- Annahmen:
- jedes Objekt gehört genau einer von mehreren potentiellen Klassen
 - es gibt bereits zu jeder Klasse Objekte, deren Klassenzugehörigkeit bekannt ist (supervised)

1 Einführung des Beispiels & Grundidee

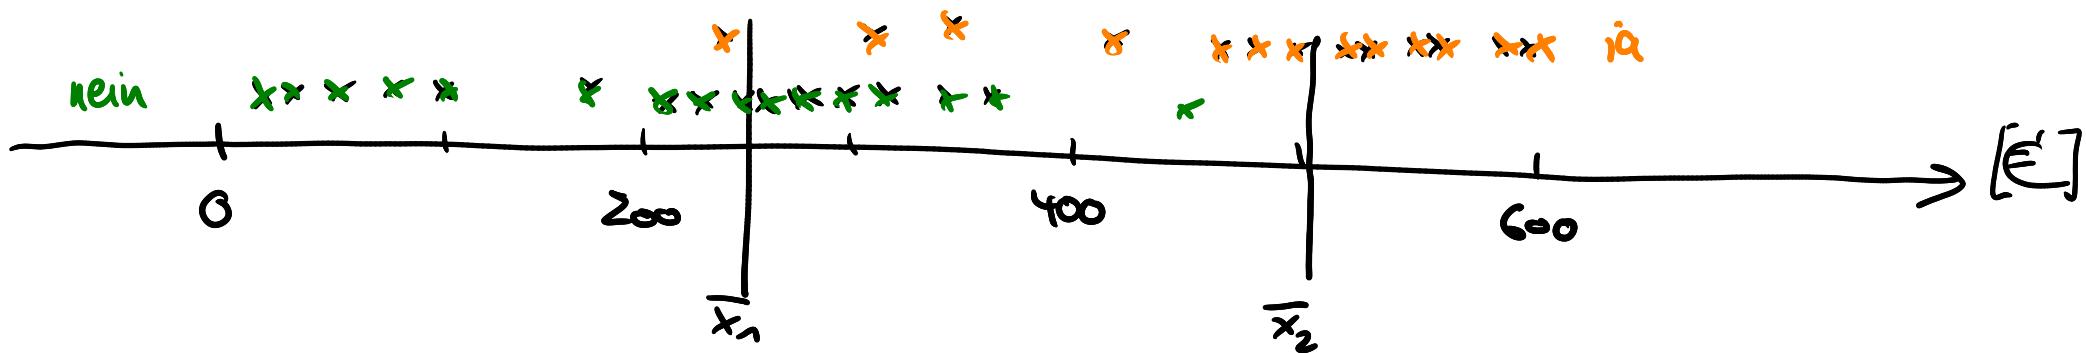
Bsp.: Für einen hochwertigen Laptop soll personalisierte Werbung durchgeführt werden. Am besten an Kunden, die sich prinzipiell Interesse haben.

FRAGE: "Hätten Sie prinzipiell Interesse?"

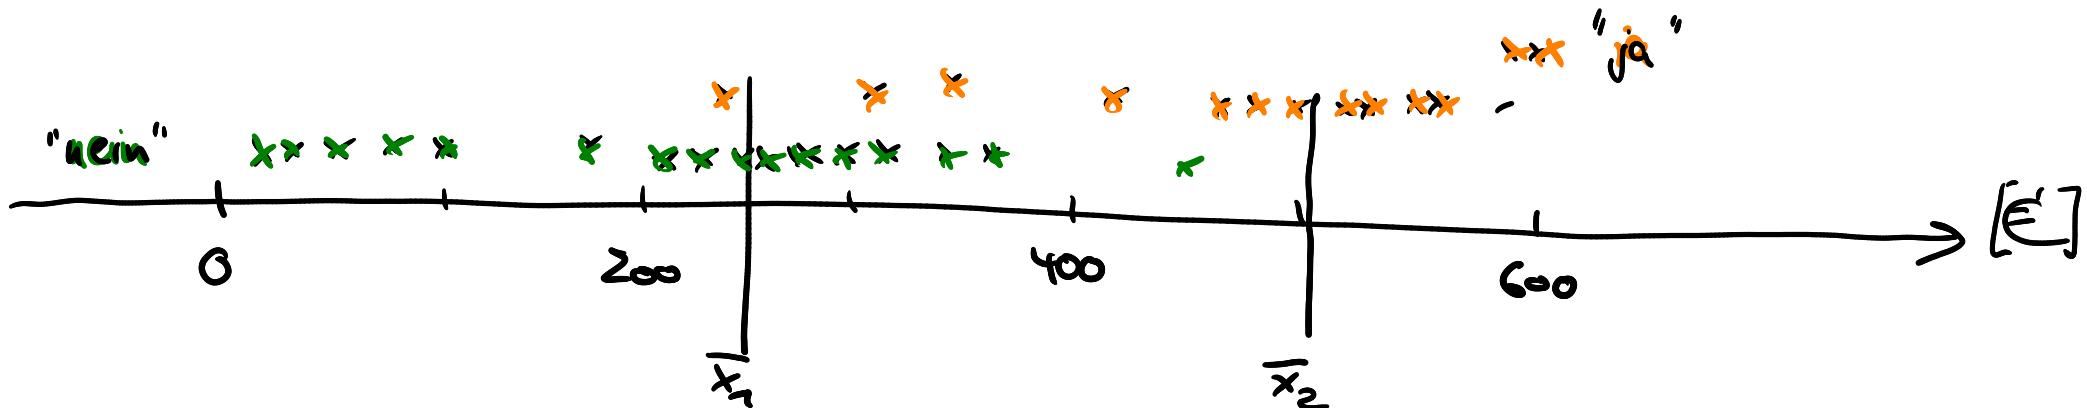
"Wieviel haben Sie im letzten Jahr für Elektronik ausgegeben?"

		Betrag [€]						
x_1^1	kein Interesse	190	430	230	110	320	...	20 Werte, $n_1 = 20$, $\bar{x}^1 = 246$ (MW)
x_1^2	Interesse	850	420	420	480	360	...	20 Werte, $n_2 = 20$, $\bar{x}^2 = 504$ (MW)

einfachste Idee: benütze die Mittelwerte der Gruppen um eine Entscheidung zu treffen!



\times : kein Interesse \checkmark Idee: Kunden, die kein Interesse am Gerät haben geben im Mittel weniger für Elektronik aus.
 \times : Interesse



↗ Bei gleicher (ähnlicher) Streuung des Merkmals "Ausgaben in €" im beiden Gruppen könnte man so entscheiden:

Falls $|x - \bar{x}^1| < |x - \bar{x}^2| \Rightarrow x \text{ in Gruppe } ①$ sonst ②

\Rightarrow kleinster Abstand zum Gruppenmittel entscheidet!

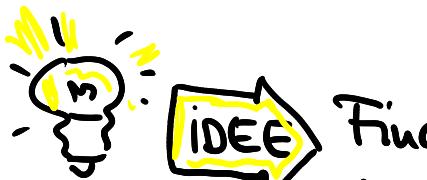
Gilt immer ☺

ABER: ziemlich fehleranfällig, wenn die Gruppen große Überschneidungsbereiche haben.

⇒ weiteres zusätzliches Merkmal

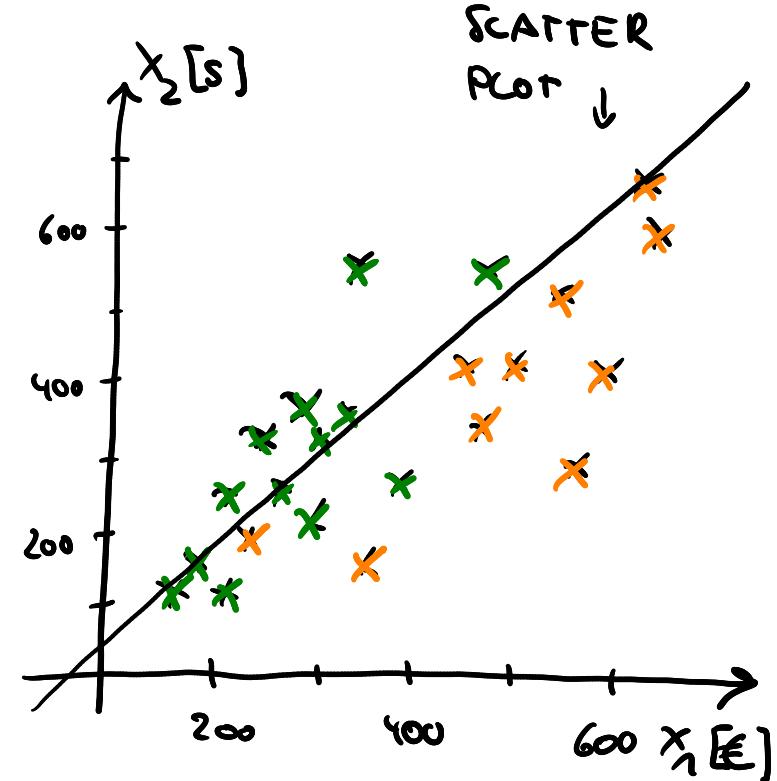
"Wieviele Zeit (s) verbringen Sie pro Tag auf Webseiten mit Elektronikprodukten?"

x_1^1	keinnt	190	480	230	110	320	... $\leftarrow [\text{€}]$
x_2^1	- - -	160	270	150	60	100	... $\leftarrow [\text{s}]$
x_1^2	Inter.	350	420	420	480	360	... $\leftarrow [\text{€}]$
x_2^2	- - -	220	190	70	210	150	$\leftarrow [\text{s}]$



Finde eine "optimale" Gerade,
die die Objekte trennt!

→ aber: was ist optimal??



✗ kein Interesse
✗ Interesse

... vielleicht kann man die erste Idee mit den Mittelwerten übertragen?



Eine Linearkombination der beiden Merkmale ergibt eine neue Variable

Ausatz:

$$y_j = a_1 x_{j1} + a_2 x_{j2}$$

← Koeffizienten
 a_1, a_2

$j=1, \dots, n$ Datenpunkte

→ Wähle die Koeffizienten a_1, a_2 so, dass die neue Größe y eine möglichst große Streuung zwischen beiden Gruppen und eine möglichst kleine Streuung innerhalb der Gruppen besitzt! \Rightarrow separiert die Gruppen optimal

Mit optimalen a_1, a_2 gilt:

$$|y - \bar{y^1}| < |y - \bar{y^2}| \Rightarrow (x_1, x_2) \text{ in Gruppe } ①$$

② sonst

dabei ist . $x = (x_1, x_2)$ neuer Objekt das zugeordnet werden soll

- $y = a_1 x_1 + a_2 x_2$ neuer Objekt in neuer Variabendarstellung
- \bar{y}_1 Mittelwert der $y_j = a_1 x_{j1} + a_2 x_{j2}$ im Gruppe 1
- \bar{y}_2 Mittelwert der $y_i = a_1 x_{i1} + a_2 x_{i2}$ im Gruppe 2

② Bestimmung der Koeffizienten a_1, a_2

Betrachte s_w^2 : Streuung der y -Werte innerhalb der Gruppen

s_b^2 : Streuung der y -Werte zwischen den Gruppen

"optimal" $\hat{a} = s_b^2 \text{ groß}, s_w^2 \text{ klein} \Rightarrow$ maximiere

$$\hat{a} = \frac{s_b^2}{s_w^2}$$

← Quotient der Streuungen

wir brauchen also s_f^2 und s_w^2 um eine Darstellung für λ zu finden ...

(138)

EXKURS: Streuungszerlegung

Allgemein: Stichprobe mit Umfang n , k Gruppen

• k Gruppen mit n_1, n_2, \dots, n_k Elementen

$\bar{x}_1, \bar{x}_2, \dots, \bar{x}_k$ Mittelwerte der Gruppen

$\sigma_1^2, \sigma_2^2, \dots, \sigma_k^2$ Varianzen der Gruppen

dann gilt:

$$n = n_1 + n_2 + \dots + n_k$$

$$\bar{x} = \frac{1}{n} (n_1 \bar{x}_1 + n_2 \bar{x}_2 + \dots + n_k \bar{x}_k)$$

dann ist die externe Varianz die Varianz der Gruppenmittelwerte

139

EXTERNE
VARIANZ

→

$$\sigma_{\text{ext}}^2 = \frac{1}{n} (u_1 (\bar{x}_1 - \bar{x})^2 + \dots + u_k (\bar{x}_k - \bar{x})^2)$$

und die interne Varianz beschreibt die Variabilität innerhalb der Gruppen

$$\sigma_{\text{int}}^2 = \frac{1}{n} (u_1 \sigma_1^2 + \dots + u_k \sigma_k^2)$$

und es gilt:

$$\sigma^2 = \sigma_{\text{int}}^2 + \sigma_{\text{ext}}^2$$

← STREUUNGSZERLEGUNG

INTERPRETATION

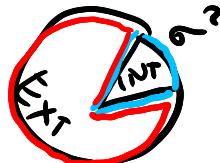
homogenität

kleine Untersch. zwischen den Gruppen

große Untersch. zwischen den Gruppen

σ_{int}^2 groß, σ_{ext}^2 klein

σ_{int}^2 klein, σ_{ext}^2 groß



bei uns ist die Variable für die wir uns interessieren

$$y_j = a_1 x_{j1} + a_2 x_{j2}$$

$$j=1, \dots, n$$

Also gilt:

$$S_w^2 = (a_1, a_2) C_w \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$$

$$S_b^2 = (a_1, a_2) C_b \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$$

wobei C_b : Kovarianzmatrix von X_1, X_2 zwischen den Gruppen

C_w : Kovarianzmatrix von X_1, X_2 innerhalb der Gruppen

Wie rechnen im unserem Beispiel C_b und C_w konkret aus?

KLAR: Für 2 Features X_1, X_2 und 2 Gruppen müssen beide Matrizen 2×2 sein...

Sei

\bar{x}_1, \bar{x}_2 Mittelwert von x_1, x_2
für alle Daten

\bar{x}_1^1, \bar{x}_2^1 Mittelwert von x_1, x_2
im Gruppe 1 (2 analog)

$\text{Var}^1(x_1), \text{Var}^1(x_2)$ Varianzen von x_1, x_2
 $\text{Var}^2(x_1), \text{Var}^2(x_2)$ bzgl. Gruppen 1 und 2

$\text{Cov}^1(x_1, x_2)$, Kovarianz von x_1, x_2
 $(\text{Cov}^2(x_1, x_2))$ bzgl. Gruppen 1 und 2

$$C_b = \begin{bmatrix} \frac{1}{n_1+n_2} (n_1(\bar{x}_1 - \bar{x})^2 + n_2(\bar{x}_2 - \bar{x})^2) & \frac{1}{n_1+n_2} \left(n_1 (\bar{x}_1 - \bar{x})(\bar{x}_2 - \bar{x}) + n_2 (\bar{x}_1 - \bar{x})(\bar{x}_2 - \bar{x}) \right) \\ \frac{1}{n_1+n_2} \left(n_1 (\bar{x}_1 - \bar{x})(\bar{x}_2 - \bar{x}) + n_2 (\bar{x}_1 - \bar{x})(\bar{x}_2 - \bar{x}) \right) & \frac{1}{n_1+n_2} (n_1(\bar{x}_1 - \bar{x}_2)^2 + n_2(\bar{x}_2 - \bar{x}_1)^2) \end{bmatrix}$$

EXTERNE
Kovarianzmatrix

(zwischen den Gruppen)

$$C_W = \begin{bmatrix} \frac{1}{n_1+n_2} (n_1 \text{Var}^1(x_1) + n_2 \text{Var}^2(x_1)) & \frac{1}{n_1+n_2} (n_1 (\text{Cov}^1(x_1, x_2) + n_2 \text{Cov}^2(x_1, x_2)) \\ \frac{1}{n_1+n_2} (n_1 (\text{Cov}^1(x_1, x_2) + n_2 \text{Cov}^2(x_1, x_2)) & \frac{1}{n_1+n_2} (n_1 \text{Var}^1(x_2) + n_2 \text{Var}^2(x_2)) \end{bmatrix}$$

INTERNE

Kovarianzmatrix

(innerhalb der Gruppen)

Mit

$$S_w^2 = (a_1, a_2) C_W \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$$

$$S_b^2 = (a_1, a_2) C_b \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$$

gilt also:

$$\lambda = \frac{S_b^2}{S_w^2} = \frac{(a_1, a_2) C_b \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}}{(a_1, a_2) C_W \begin{pmatrix} a_1 \\ a_2 \end{pmatrix}} \rightarrow \max_{a_1, a_2} (\dots)$$

Maximierungsproblem!

Max gerichtet,
so dass

$$C_b \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} \rightarrow C_W \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} = 0$$

$$\Leftrightarrow (C_b - \lambda C_W) \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} = 0$$
*

falls C_w vollen Rang hat $\Rightarrow C_w$ ist invertierbar (x_1, x_2 unabhängig, bzw nicht kollinear!) 743

\Rightarrow

$$(C_w^{-1} C_b \rightarrow \text{Id}) \begin{pmatrix} a_1 \\ a_2 \end{pmatrix} = 0$$

Eigenwertproblem



\Rightarrow Suche Eigenvektor $\begin{pmatrix} a_1 \\ a_2 \end{pmatrix}$ zum größten Eigenwert λ !

dann

$$y = a_1 x_1 + a_2 x_2$$

neue Variable mit Entscheidungskriterium

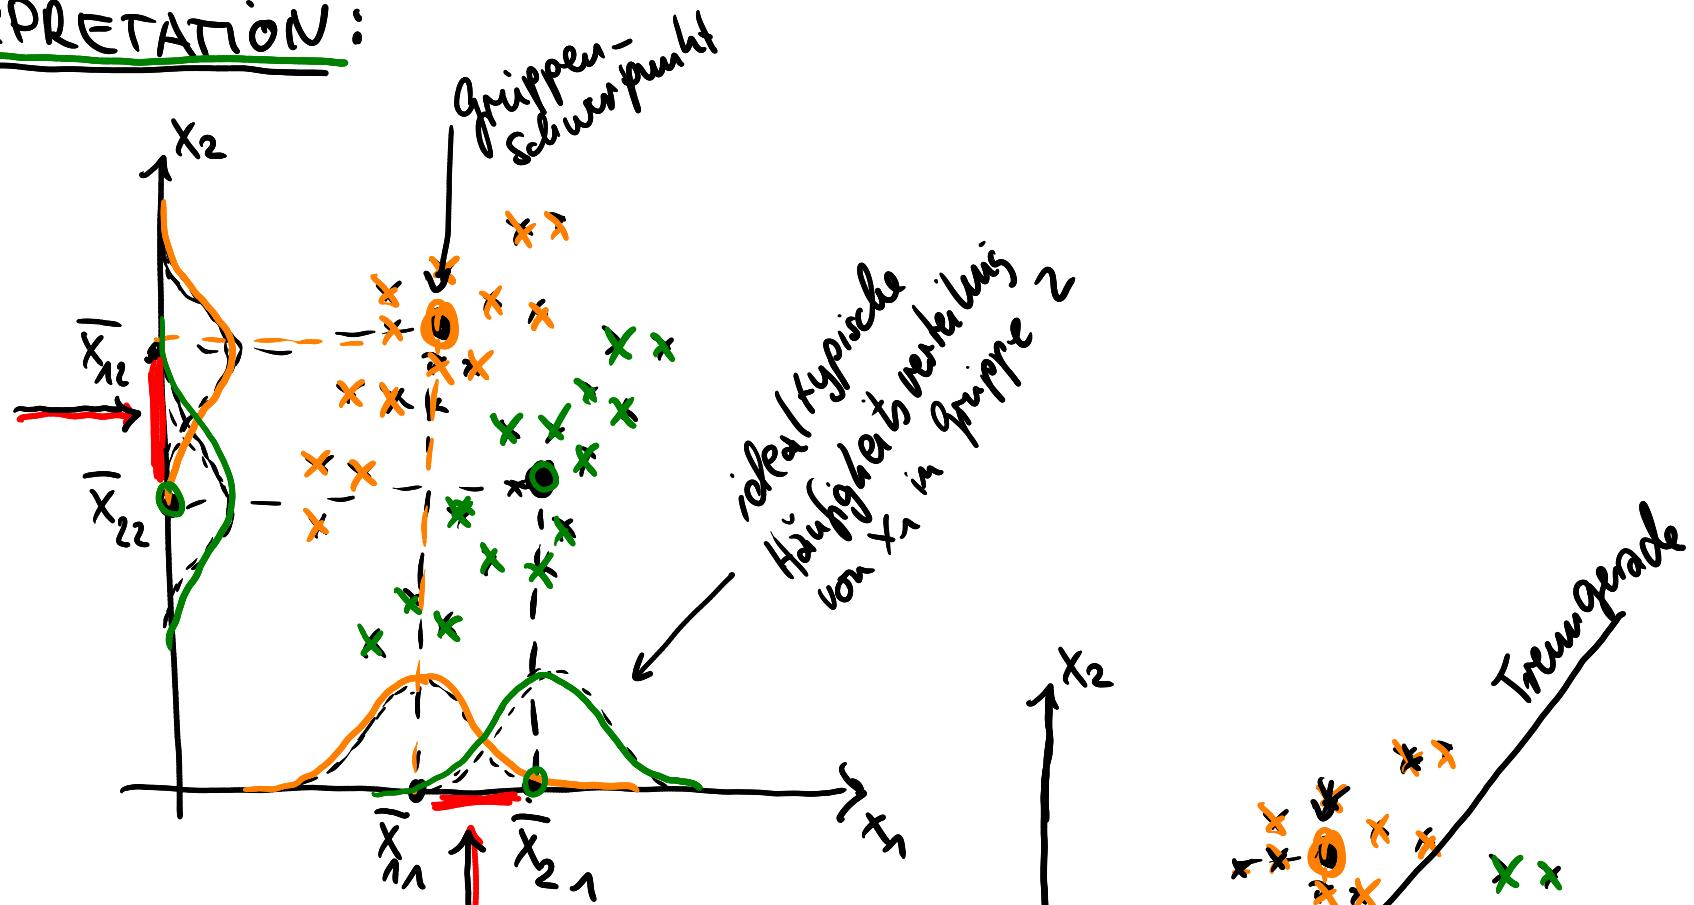
Gruppe
② sonst

$$|y - \bar{y}_1| < |y - \bar{y}_2| \Rightarrow (x_1, x_2) \text{ in Gruppe } ①$$

Die Lösung des Eigenwertproblems liefert uns also genau die neue Variable y , für die das Entscheidungskriterium die beste Trennschärfe für die beiden Gruppen besitzt

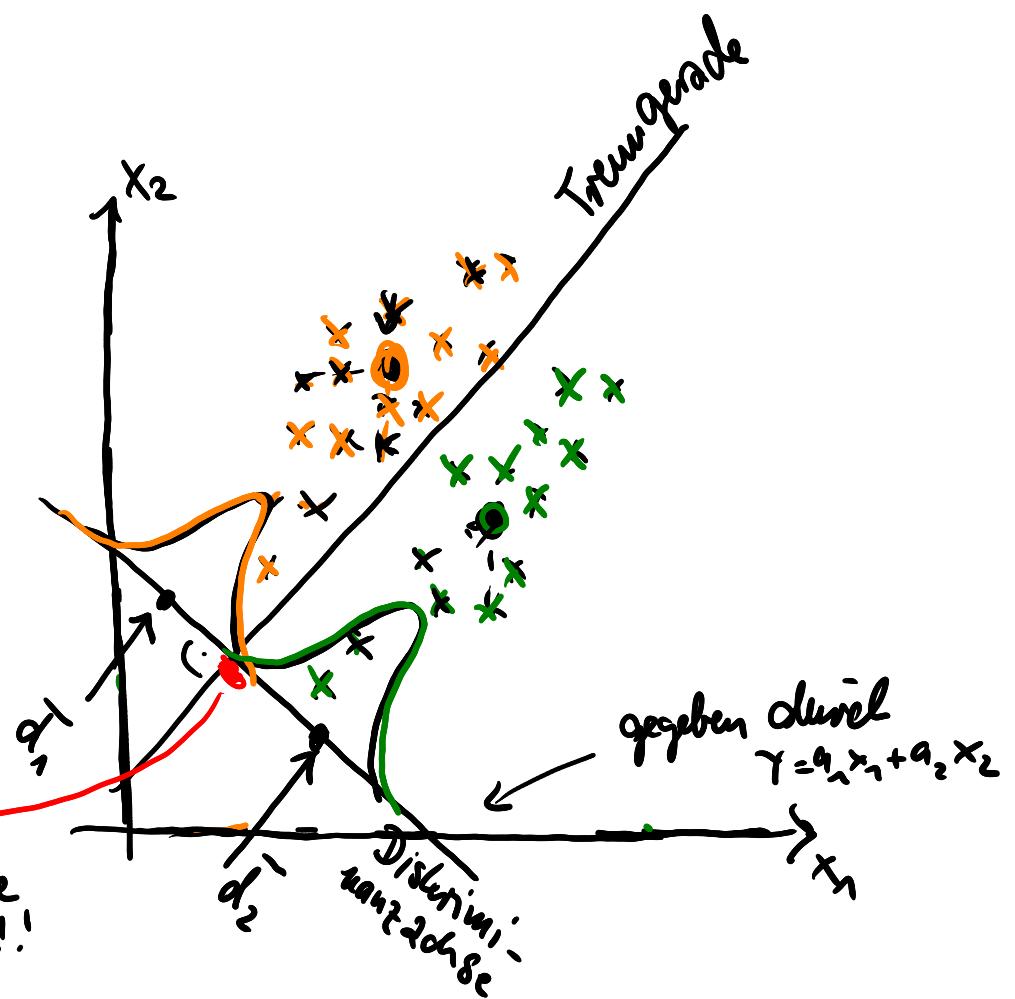
INTERPRETATION:

144



kritischer
Bereich für
Fehlzuordnungen

minimal
⇒ Trennschärfe
optimal !!



Allgemeine Formulierung

145

LINEARE DISKRIMINANZANALYSE (LDA)

AUSGANGSLAGE

- Gesamtheit mit \rightarrow Gruppen (Zuordnung bekannt)
- k unterschiedliche Merkmale (= Features)
- jeweils n_i ($i = 1, \dots, r$) Beobachtungen in Gruppe i
- beliebige (neue) Beobachtung $x = (x_1, \dots, x_k)$
- j -te Beobachtung in Gruppe i $x_j^i = (x_{j,1}^i, \dots, x_{j,k}^i)$ ($j = 1, \dots, n_i$)

- ① lineare Diskriminanzanalyse \Rightarrow Verallgemeinerung des vorigen Beispiels
- ② Erweiterung: Zuordnung mit Hilfe kanonischer Variablen

I. Aufgabenstellung

146

Die lineare Diskriminanzanalyse basiert auf der (linearen)

DISKRIMINANZFUNKTION

$$y = \alpha_1 x_1 + \dots + \alpha_k x_k$$

mit Gruppenmittelwerten

$$\bar{y}^i = \frac{1}{n_i} \sum_{j=1}^{n_i} y_j^i$$

Für einen Punkt $x = (x_1, \dots, x_k)$ mit unbekannter Zuordnung gilt dann für

$$y = \alpha_1 x_1 + \dots + \alpha_k x_k$$

x gehört zu derjenigen Gruppe i für die $|y - \bar{y}^i|$ minimal ist ($i = 1, \dots, r$)

dabei gilt: Die Diskriminanzfunktion soll so gewählt werden, dass sie möglichst trennscharf ist, d.h.

für

$$\left. \begin{aligned} S_w^2 &= \frac{1}{n} \sum_{i=1}^r \sum_{j=1}^{n_i} (y_j^i - \bar{y}_i)^2 \\ S_b^2 &= \frac{1}{n} \sum_{i=1}^r n_i (\bar{y}_i - \bar{y})^2 \end{aligned} \right\}$$

$\frac{S_b^2}{S_w^2} = 1$

maximal

II. LÖSUNG DES MAXIMIERUNGSPROBLEMS

Sei $\bar{x} = (\bar{x}_1, \dots, \bar{x}_k)$ ← Zeilenvektor der Mittelwerte der k Merkmale (alle Gruppen)

$\bar{x}^i = (\bar{x}_1^i, \dots, \bar{x}_k^i)$ ← Vektoren der Mittelwerte der k Merkmale in den r Gruppen
 $(i=1, \dots, r)$

$C^i = \frac{1}{n_i} \sum_{j=1}^{n_i} (x_j^i - \bar{x}^i)^t (x_j^i - \bar{x}^i)$ Kovarianzmatrix innerhalb der i-ten Gruppe
 $(i=1, \dots, r)$

Dann gilt für $C_w = \frac{1}{n} \sum_{i=1}^k m_i C^i$ und $C_b = \frac{1}{n} \sum_{i=1}^k m_i (\bar{x}^i - \bar{x})^t (\bar{x}^i - \bar{x})$

sowie $\vec{a}^t = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix}$ Koeffizientenvektor $\vec{a} = (a_1, \dots, a_n)$

$$\lambda = \frac{\begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix} C_b \begin{pmatrix} a_1 & \dots & a_n \end{pmatrix}}{\begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix} C_w \begin{pmatrix} a_1 & \dots & a_n \end{pmatrix}}$$

$$\Leftrightarrow \boxed{C_b \vec{a} = \lambda C_w \vec{a}}$$

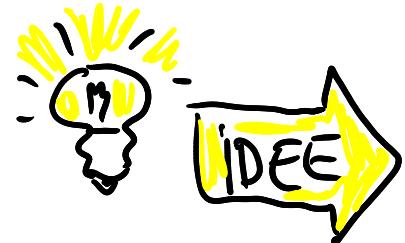
$$B \vec{a} = \lambda W \vec{a}$$

verallgemeinertes
symmetrisches
Eigenwertproblem

$$\Leftrightarrow \boxed{(C_w^{-1} C_b - \lambda \cdot \text{Id}) \vec{a}^t = 0}$$

 Der gerichtete Vektor \vec{a} entspricht dem Eigenvektor zum größten Eigenwert λ !

 EV normiert bzgl W(C_w): $\vec{a}^t W \vec{a} = 1$



Betrachte die erklärte Streuung
= Streuung zwischen den Gruppen

$$\lambda = \frac{s_b^2}{s_w^2}$$

, dann

$$\frac{\text{erklärte Streuung}}{\text{Gesamtstreuung}} = \frac{s_b^2}{s_w^2 + s_b^2} = \frac{\lambda}{1+\lambda}$$

→ Itemgß: kanonischer Korrelationskoeffizient
"je größer desto besser 😊"

$$C = \sqrt{\frac{\lambda}{1+\lambda}} \in [0;1]$$

$\in [0;1]$

manchmal auch andersrum

$$\lambda = \frac{1}{1+\lambda}$$

Wilks-Lambda $\in [0;1]$

"Anteil der nicht-erklärten Streuung an der Gesamtstreuung" \Rightarrow top ist $\lambda = 0$!

Bemerkung:

Vorteile der LDA :

- intuitiv verständlich
- analytische Lösung
- keine Beta-Parameter
- kann als Dimensionsreduktion interpretiert werden

$\Rightarrow y = q_1x_1 + \dots + q_nx_n$ lässt sich visualisieren!

UND: LDA lässt sich so erweitern, dass auch weitere Eigenwerte und -vektoren des EWP $G\vec{q} = \lambda C_w \vec{\alpha}$ mit berücksichtigt werden:

VORTEIL: Auch die restliche Streuung der Merkmale wird bei der Klassifikation berücksichtigt \Rightarrow mehr Trennschärfe !!

Ausblick : Zuordnung mit Hilfe kanonischer Variablen

151

Sind $\vec{a}^1, \dots, \vec{a}^q$ Eigenvektoren zu den positiven EW
 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_q$

so lassen sich für eine beliebige Beobachtung $x = (x_1, \dots, x_k)$

die KANONISCHEN VARIABLEN $y_j = \bar{x} \vec{a}^j$ ($j=1, \dots, q$) definieren.

für die kanonischen Variablen der Gruppenmittel \bar{x}^i (Vektoren)
schreibt man \bar{y}_j^i ($i=1, \dots, r$; $j=1, \dots, q$)

Ein Objekt gehört dann zu der Gruppe, für die $\sum_{i=1}^q (y_i - \bar{y}_j^i)^2$ minimal ist.